QLoRA Domain Chatbot

과목명	생성형AI프로젝트	지도교수	양영욱
팀 구성원	학번	성명	학과
	20211362	신수형	컴퓨터공학과
	20221317	지수정	컴퓨터공학과
	20251932	황재민	컴퓨터공학과

KNU 강원대학교
KANGWON NATIONAL UNIVERSITY

Index

Abstract 1

1. Introduction 1

2. Domain Selection and Chatbot Role 2
2.1. 도메인 선택 이유 2
2.2. 사용 시나리오 2
2.3. 모델 선택 3

3. Data Collection 3
3.1. 원천 자료 3
3.2. 질문-답변 작성 원칙 3
3.3. 데이터 세트 4

4. Data Processing and Chat Template Design 4
4.1. 메시지 형식 4
4.2. 학습 대상 Token Masking 4

5. Train, Validation, and Test Split 5
5.1. 분할 기준 5
5.2. 20,000문항 split 구성 5

6. Training Method 5
6.1. QLoRA 설정 5
6.2. 학습 Curriculum 6

7. Evaluation Method 6

8. Experimental Results 7
8.1. 20,000문항 본 학습 7
8.2. 균형 보정 최종 학습 7

9. Analysis 8

10. Limitations and Future Work 9

11. Conclusion 9

12. References 10

Appendix A: Reproducibility 11
Appendix B: Data Artifacts 13

NeurIPS-style Course Project Report: QLoRA Domain Chatbot : 핸드폰에서 바로 질문하는 전공 공부용 로컬 AI 조교 구축

황재민[1], 신수형[1], 지수정[1]

[1]강원대학교 원주캠퍼스 컴퓨터공학과

Abstract

본 프로젝트는 생성형 AI 강의 자료를 기반으로 QLoRA fine-tuning을 적용한 도메인 특화 Q&A 챗봇을 구축하였다. 전공 공부를 하다 보면 학생들은 강의 자료를 읽으며 궁금한 내용이 있을 때 AI에 질문함으로써 학습에 도움을 받을 수 있다. 하지만, 이는 유료 AI 서비스 이용, 네트워크 연결, 개인정보 노출, 수업 범위를 벗어난 잘못된 답변 등의 제약을 겪는다. 본 프로젝트는 이러한 문제를 핸드폰에서 무료로 바로 실행할 수 있는 로컬 전공 공부 AI 조교라는 사용 시나리오로 정의하고, 그 기반이 되는 경량 도메인 특화 LLM을 구축하였다.

강의에서 사용된 PDF를 기반으로 도메인 데이터를 직접 수집하고 정제한 뒤, 사전학습 언어 모델 Qwen2.5-1.5B-Instruct를 생성형 AI 과목 학습 도우미로 특화하였다. 본 프로젝트의 목표는 일반 대화 능력을 확대하는 것이 아니라, 강의 자료 범위 안에서 학생들이 실제로 제기할 만한 질문에 대해 정확하고 쉬운 한국어 설명을 생성하는 것이다. 원천 자료는 Transformer, LLM, Prompt Engineering, GAN, Diffusion model, LoRA/QLoRA, SFT 등을 다루는 8개 강의 PDF이다. PDF 당 75개씩 총 600개 핵심 Q&A를 기준 개념 세트로 구성하였고, 같은 600개 개념을 다양한 질문 표현으로 확장하기 위해 train, validation, test를 재구성하여 최종적으로 20,000개 학습 문항, 600개 검증 문항, 600개 테스트 문항을 마련하였다.

모델 학습은 강의에서 다룬 QLoRA 원리에 따라 사전학습 가중치를 4-bit NF4로 고정하고, attention 및 feed-forward projection에 LoRA adapter만 업데이트하는 방식으로 수행하였다. 학습 데이터는 Qwen Instruct 계열 chat template에 맞춘 SFT 형식으로 가공하였으며, assistant 답변 토큰에만 손실을 계산하는 instruction tuning 구조를 따랐다. 잔존 오류를 수정하되 다른 개념이 손상되지 않도록 720개 균형 보정 데이터를 추가 학습하였다. 최종 모델은 미학습 질문 표현 600개로 구성된 in-concept paraphrase test에서 600/600을 통과하였고, 외국어 문자 혼입은 0건이었다. 이 결과는 향후 모바일 On-Device 배포를 위한 도메인 adapter의 실현 가능성을 시사하며, 새로운 개념에 대한 일반화 성능이라기보다 학습한 강의 개념을 다른 표현으로 질문했을 때의 견고한 회상과 설명 능력으로 해석해야 한다.

1. Introduction

전공 공부에서 가장 답답한 순간 중 하나는 모르는 개념이 생겼을 때 즉시 질문할 상대가 없다는 점이다. 강의 PDF를 읽다가 Transformer[1]의 Query/Key/Value가 Scaled Dot-Product Attention에서 각각 어떤 역할을 하는지, decoder self-attention에서 왜 미래 토큰을 가려야 하는지, zero-shot과 few-shot 프롬프트의 차이 등을 이해하는 데 어려움을 느껴도 그 순간에 교수님 또는 조교에게 질문할 수는 없다.

GAN[2]의 minimax 목적함수와 mode collapse, Diffusion model[3]의 forward process에서 noise가 어떻게 주입되고 reverse process에서 U-Net이 무엇을 예측하는지, QLoRA[4]에서 4-bit NF4 양자화와 Low-Rank LoRA[5] adapter가 각각 어떤 역할을 하는지 등도 마찬가지이다. 범용 AI 서비스를 이용할 수는 있으나, 무료 사용량 제한, 구독 비용, 네트워크 연결, 로그인, 강의 자료 업로드에 따른 개인정보 부담이 따른다. 또한, 범용 모델은 타당해 보이는 일반 설명을 제공하더라도 수업에서 사용한 예시와 강조점에서 벗어날 수 있다. 예를 들어 GAN의 mode collapse를 설명할 때 수업 실습에서 강조한 학습률 불균형, 또는 Diffusion model을 설명할 때

DDPM의 noise schedule과 timestep embedding 같은 표현이 빠질 수 있다.

본 프로젝트는 이러한 문제를 핸드폰 속 전공 공부 조교라는 관점에서 해결하고자 한다. 학생이 통학 중, 도서관, 시험 직전, 인터넷 연결이 불안정한 환경에서도 핸드폰에서 로컬 LLM을 열고 바로 질문할 수 있다면 전공 공부의 접근성이 크게 향상될 것이다. 서버 API를 호출하지 않으므로 장기적으로 무료 사용이 가능하고, 강의 자료 기반 adapter를 기기에 탑재하는 방식이므로 개인 학습 질문이 외부 서버로 전송되지 않는다는 장점도 있다. 지금 단계에서는 실제 모바일 앱 배포 단계까지 진행하진 않지만, 경량 모델 Qwen2.5-1.5B-Instruct[6]를 선택하고 QLoRA adapter 형태로 과목 지식을 압축한 것은 전공 공부형 로컬 AI 조교를 구축하는 첫 단계라 말할 수 있다. 이는 수업 후반부에서 다룬 fine-tuning 이론, 즉 전체 가중치를 갱신하는 full fine-tuning 대신 frozen base model 위에 소수 파라미터 adapter만 학습하는 parameter-efficient fine-tuning 전략을 실제 도메인 Q&A에 적용한 결과이다.

본 프로젝트의 목적은 생성형 AI 과목 강의 자료를 바탕으로, 학생의 질문에 대해 강의 자료 기준의 쉽고 정확한 답변을 제공하는 도메인 특화 챗봇을 구현하는 것이다. Prompt Engineering만으로도 특정 작업 성능을 끌어올릴 수 있음을 중간 실험에서 확인하였으나, 강의 PDF 전 범위의 개념을 일관된 조교 어조로 설명하려면 도메인 Q&A에 대한 SFT가 더 적합하다고 판단하였다. 최종 600/600은 in-concept paraphrase test 결과로, 학습한 600개 강의 개념을 다른 질문 표현으로 물었을 때의 성능을 뜻한다. 강의 자료 밖의 완전히 새로운 개념(unseen concept)까지 답변을 보장하는 결과는 아니다.

2. Domain Selection and Chatbot Role

2.1. 도메인 선택 이유

도메인은 생성형 AI 강의 Q&A로 정한 이유는 다음과 같다. 본 프로젝트는 사전학습 LLM을 직접 수집한 도메인 데이터로 fine-tuning 하는 것을 목표로 하므로, 생성형 AI 강의 Q&A 도메인이 주제와 직접 연결되어 결과를 검증하기에 유리하다 판단하였다. 강의 PDF는 수업 범위를 정의하는 1차 자료이므로 데이터 출처가 명확하고 정답 기준 설정이 다른 데이터에 비하여 쉬울 것으로 판단하였다. 또한, 학생들이 실제로 제기할 법한 질문을 설계하고 강의 자료 기준의 정확성을 검증할 수 있어 평가도 실용적이다. 마지막으로 학생이 핸드폰에서 로컬 LLM을 실행해 전공 개념을 무료로 바로 질문하는 개인 과목 조교로 확장할 수 있어 사용 시나리오도 분명하므로 생성형 AI 강의 Q&A를 도메인으로 설정하였다.

따라서 본 챗봇은 범용 검색 엔진이나 잡담 챗봇이 아닌, 생성형 AI 과목 학습 도우미이자 향후 핸드폰 속 로컬 전공 조교로 이용할 수 있도록 설계하였다. 답변 정책은 다음과 같이 정하였다. 강의 자료 범위 안에서 설명하고, 학생이 이해할 수 있는 쉬운 한국어를 사용하며, Transformer, LoRA, QLoRA, Diffusion model 등 영어 기술 용어는 억지로 번역하지 않고 그대로 사용하였으며, 모르는 내용은 강의 자료 밖의 추측으로 확장하지 않도록 하였다.

2.2. 사용 시나리오

전공 공부형 로컬 AI 조교의 사용자는 시험을 준비하거나 과제를 수행하면서 전공 개념을 빠르게 확인하고 싶은 학생이다. 학생은 강의 PDF를 읽다가 masked decoder self-attention이 왜 미래 단어를 참조하면 안 되는지, few-shot 예시를 넣었을 때 Chain-of-Thought[7]가 어떤 경우에 도움이 되는지, mode collapse가 왜 GAN의 대표적 실패 사례인지, DDPM에서 forward process와 reverse process가 각각 무엇을 의미하는지, QLoRA에서 4-bit NF4 양자화와 LoRA adapter가 각각 어떤 역할을 하는지 등을 질문한다. 챗봇은 인터넷 검색 결과를 나열하는 대신, 해당 과목의 강의 자료에서 배운 표현을 바탕으로 짧고 정확하게 답변한다.

이 시나리오에서 로컬 LLM은 비용 절감, 학습 접근성, 개인정보 보호 측면에서 강점을 가진다. API 호출이나 구독 없이 기기 안에서 실행할 수 있어 비용 장벽을 낮추고, 공부 중에도 핸드폰만 열면 바로 질문할 수 있어 학습 흐름이 단절되지 않으며, 학생의 질문과 강의 자료 기반 adapter가 외부 서버로 지속 전송되지 않는 구조를 지향할 수 있다. 따라서, 본 프로젝트의 fine-tuning은 단순히 모델 점수를 높이는 실험이 아니라, 전공 공부 경험을 질문 가능한 교재로 전환하는 기반 작업이다.

2.3. 모델 선택

기반 모델은 Qwen2.5-1.5B-Instruct를 사용하였다. 1.5B 규모로 제한된 GPU에서도 QLoRA 학습이 가능하고, Instruct 모델이므로 system, user, assistant 메시지 구조를 따르는 챗봇형 데이터와 잘 부합한다. 수업에서 다룬 LLM 기본 개념에 따르면, Instruct 모델은 chat template를 통해 역할별 메시지를 하나의 프롬프트로 변환한 뒤 causal language modeling으로 답변을 생성하므로, 본 프로젝트의 SFT 데이터 형식과도 일치한다. 또한, 4-bit 또는 GGUF 계열 양자화 모델로 변환해 모바일 기기에서 실행하도록 하는 이후의 단계를 구상하기에도 적합하다. 규모가 큰 모델은 일반 성능 면에서 유리할 수 있으나, 핸드폰에서 무료로 바로 질문하는 로컬 AI 조교라는 목표에는 작고 특화된 모델이 더 설득력이 있다. 본 프로젝트에서는 재현 가능한 fine-tuning, 제한된 GPU 자원, 데모 안정성을 중시하였기 때문에 1.5B 모델을 유지하였다.

3. Data Collection

3.1. 원천 자료

원천 자료는 생성형 AI 과목 폴더의 강의 PDF 8개이다. 각 PDF에서 학생들이 질문할 만한 개념을 추출하였고, 자료 간 균형을 맞추기 위해 PDF 당 75개 Q&A로 기준 세트를 구성하였으며, 내용은 [Table 1]과 같다.

파일	내용	Q&A 수
01. Transformer.pdf	Transformer, Self-Attention, QKV, 전처리, 토큰화	75개
02. LLM에 대한 기본 지식.pdf	LLM, tokenizer, chat template, 모델 선택	75개
03. 프롬프트 엔지니어링1.pdf	zero-shot, few-shot, Chain-of-Thought, prompt 구성 요소	75개
04. 프롬프트 엔지니어링2.pdf	Self-Consistency, Tree-of-Thought, Self-Refine, 구조화 출력	75개
08. GAN.pdf	GAN 구조, minimax, mode collapse, 잠재공간	75개
09. GAN의 변형.pdf	DCGAN, pix2pix, U-Net, PatchGAN, GAN 실습	75개
10. Diffusion model.pdf	DDPM, DDIM, U-Net, latent diffusion, guidance	75개
11. 파인튜닝.pdf	LoRA, QLoRA, 데이터 품질, hyperparameter, SFT	75개
합계	생성형 AI 과목 핵심 개념	600개

[Table 1] 원천 강의 자료와 기준 Q&A 수

3.2. 질문-답변 작성 원칙

질문은 실제 학생이 복습 중 질문으로 사용할만한 형태로 작성하였다. 예를 들어 Self-Attention에서 Query, Key, Value는 각각 무슨 역할을 하는지, GAN의 minimax 목적함수는 무엇을 의미하는지, QLoRA에서 Q가 quantum이 아니라 무엇을 뜻하는지와 같이 수업 내용을 확인하는 질문을 중심으로 구성하였다.

답변은 강의 자료에 있는 범위와 표현을 우선하고, 정의만 나열하지 않고 학생이 이해할 수 있도록 직관적 설명을 함께 제공하도록 구성하였다. 답변 길이는 보통 2~4문장으로 제한하였으며, 같은 개념의 인접 주제끼리 답변이 혼재되지 않도

록 핵심 키워드를 명확히 두었다. 또한, 한국어 문장 안에는 필요한 영어 기술 용어만 유지하고, 불필요한 외국어 문자는 제거하였다.

3.3. 데이터 세트

초기에는 PDF 텍스트와 강의 주제를 바탕으로 1,030개 Q&A 후보를 작성하고, 중복 질문과 형식 오류를 검사하였다. 이후 데모와 평가 안정성을 위해 [Table 1]에 기술한 것처럼 PDF 당 75개씩 총 600개 핵심 개념 세트를 확정하였다. 최종 20,000개 학습 데이터는 20,000개의 서로 다른 개념을 뜻하지는 않으며, 600개 핵심 개념을 여러 질문 표현으로 반복하여 학생이 같은 내용을 다르게 물어봐도 답할 수 있도록 구성하였다.

4. Data Processing and Chat Template Design

4.1. 메시지 형식

학습 데이터는 JSONL(JSON Lines) 형식으로 저장하였다. 다음은 하나의 대화 예시이며, Qwen Instruct 계열의 chat template에 맞게 system, user, assistant 세 역할을 사용하였다.


```
{  "source_pdf": "11. 파인튜닝.pdf",
  "topic": "QLoRA",
  "messages": [
    {
      "role": "system",
      "content": "너는 생성형 AI 과목을 듣는 학생에게 강의 자료 기준으로 쉽고 정확하게 설명하는 조교다."
    },
    {
      "role": "user",
      "content": "QLoRA에서 Q는 quantum이 아니라 뭘 뜻하나요?"
    },
    {
      "role": "assistant",
      "content": "QLoRA에서 Q는 Quantized, 즉 양자화를 뜻합니다. QLoRA는 사전학습 모델의 가중치를 4-bit 같은 낮은 정밀도로 양자화해 메모리를 줄이고, 그 위에 LoRA 어댑터만 학습해 큰 모델도 제한된 GPU에서 파인튜닝할 수 있게 합니다."
    }
  ]
}
```


추론용 system prompt는 학습 때보다 한국어 출력을 더 엄격히 요구하도록 정함으로써 필요한 영어 기술 용어는 그대로 사용하되, 문장은 반드시 자연스러운 한국어로 작성하도록 명시하였다. 이 프롬프트는 외국어 혼입을 줄이고, 답변 어조를 수업 조교에 가깝게 유지하는 것을 목적으로 작성하였다.

4.2. 학습 대상 Token Masking

SFT에서는 사용자 질문과 system prompt를 그대로 생성하도록 학습하는 것이 아니라, assistant 답변 부분에만 손실(loss)을 계산한다. 학습 스크립트는 tokenizer.apply_chat_template()[8]로 prompt 부분과 전체 대화를 각

각 토큰화한 뒤, prompt에 해당하는 label을 -100으로 마스킹하였다. 따라서, loss는 assistant 응답 토큰에 대해서만 계산되며, 이 방식은 역할 구분을 유지하면서 챗봇 답변만 학습시키는 표준적인 instruction tuning 구조이다.

5. Train, Validation, and Test Split

5.1. 분할 기준

본 프로젝트의 목표는 강의 자료 범위 안에서 질문에 답하는 챗봇을 구현하는 것이기에 평가는 두 개로 나누었다. Train recall은 학습에 넣은 원본 Q&A를 그대로 다시 물었을 때 맞히는지 확인하는 용도로, 또 다른 하나인 in-concept paraphrase test는 같은 600개 강의 개념을 학습에 없던 다른 질문 문장으로 물었을 때 맞히는지 확인하기 위하여 나누었다. 원본 질문만 암기한 수준이면, 학생이 표현을 조금만 바꾸어 질문했을 때 실패할 수 있기에 in-concept paraphrase test의 평가가 더욱 중요하다고 볼 수 있다.

5.2. 20,000문항 split 구성

최종 Split은 600개 핵심 개념을 기준으로 구성하였다. Train에는 각 개념당 33개의 새 질문 표현을 만들고, 초기 실험에서 성능이 약했던 15개 개념에 대해 200개의 보강 질문을 추가하여 문항을 구성하였다. Validation과 Test는 같은 600개 개념에 대해 학습에 사용하지 않은 새 질문 표현으로만 구성하였다. 문항의 전체 구성은 [Table 2]와 같다.

구분	문항 수	의미
Train	20,000	600개 개념의 다양한 학습 질문 표현 19,800개 + 취약 개념 보강 200개
Validation	600	같은 600개 개념을 학습에 없는 표현으로 질문
Test	600	같은 600개 개념을 또 다른 미학습 표현으로 질문
All	21,200	Train, Validation, Test 전체 합계

[Table 2] Concept 20000 Split 구성

중복 검사는 질문 문자열 기준으로 수행하였다. 최종 manifest 기준으로 Train, Validation, Test 간 질문 문자열 중복은 0개였고, 기존 concept 3000 및 concept 9000 split과도 Train 질문 문자열 중복이 0개였다. 따라서, Test 질문 문자열 자체를 그대로 학습시킨 것은 아니다. 다만, 평가 대상 개념은 Train, Validation, Test 모두 같은 600개이다. 이 평가는 Unseen-Concept(학습에 없던 새 개념) 평가가 아니라, 같은 개념에 대한 paraphrase(표현 변형) 견고성 평가이다.

6. Training Method

6.1. QLoRA 설정

학습은 서버 GPU에서 수행하였다. 기반 모델은 Qwen2.5-1.5B-Instruct이며, 메모리 절약을 위해 4-bit QLoRA를 사용하였으며, 학습 설정 내용은 [Table 3]과 같다.

항목	설정
Base model	Qwen2.5-1.5B-Instruct
Quantization	4-bit, NF4, double quantization, compute dtype FP16
Adapter method	LoRA / PEFT
LoRA rank	r = 64
LoRA alpha	128
LoRA dropout	0.0
Target modules	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj
Optimizer	AdamW
Batch size	2
Gradient accumulation	1
Max sequence length	512 tokens in final experiments
Generation for eval	greedy decoding, do_sample=False

[Table 3] QLoRA 학습 설정

LoRA rank를 64로 크게 설정한 이유는, 본 프로젝트가 일반적인 정규화보다 강의 Q&A 범위 안의 안정적 회상과 데모 성능을 우선했기 때문이다. 즉, 어느 정도 과적합을 허용하고, adapter가 강의 개념을 충분히 저장하도록 설계하였다.

6.2. 학습 Curriculum

처음부터 20,000문항만 학습한 것이 아니라, 실패 양상을 확인하면서 점진적으로 데이터와 학습 전략을 조정하였다.

단계	Train 수	Test 수	결과와 해석
원본 600 Q&A Recall	600	600	학습 문항 회상 600/600. 단, 질문 표현 변화에는 취약
Paraphrase 80 평가	600	80	69/80. 원문 암기만으로는 표현 변화에 충분히 견고하지 않음
Concept 3000	3,000	600	585/600
Concept 9000	9,000	600	599/600. 외국어 문자 혼입 0건, 실패 1건
Concept 20000	20,000	600	599/600. validation loss는 더 낮아졌으나 같은 문항 군에서 1건 실패
Balanced Repair	720	600	최종 600/600. 취약 주제 보정과 전체 개념 anchor 복습

[Table 4] 학습 Curriculum과 평가 결과

이 과정에서 확인된 중요한 점은, 특정 문제 하나만 강하게 반복 학습시키면 다른 문항이 손상될 수 있다는 것이다. 실제로 문장 분리 예외 실패만 단독 보정을 했을 때 해당 문항은 수정되었으나, 잠재 공간 벡터 연산과 parsing 실패 문항에서는 새로운 회귀 현상이 발생하였다. 따라서, 최종 보정에서는 취약 주제 target row 120개와 전체 600개 개념 anchor row 600개를 함께 사용하여 총 720개로 균형을 맞추었다.

7. Evaluation Method

평가는 loss만으로 판단하지 않고 실제 생성 답변을 기준으로 수행하였다. 각 test 예시에 대해 모델이 greedy decoding으로 답변을 생성하고, 기대 답안과 비교하였다. 평가 지표는 문자열 유사도와 핵심 키워드 겹침 두 가지이다. 문자열 유사도는 공백과 대소문자를 정규화한 뒤 Python[9] SequenceMatcher로 계산하였고, 핵

심 키워드 겹침은 기대 답안과 생성 답안에서 숫자, 영문, 한글, 기호 토큰을 추출하고 stopword를 제거한 뒤, 기대 답안 토큰 중 생성 답안에 포함된 비율을 계산하였다.

최종 concept 20000 test에서는 문자열 유사도 threshold 0.58 또는 키워드 겹침 threshold 0.45 중 하나를 충족하면 통과로 판정하였다. 이 기준은 validation 세트의 실패 사례를 점검하며 설정한 값이다. 같은 정답이라도 문장 순서나 표현이 달라질 수 있기 때문이다. 반대로 핵심 키워드가 빠지거나 인접 개념이 혼입되면 점수가 낮아져 실패로 분류된다.

초기 실험에서 일부 답변에 중국어, 일본어 문자 조각이 혼입되는 문제가 있었다. 최종 모델은 한국어 조교 역할에 맞게 답변해야 하므로, 테스트 결과 JSON 전체를 대상으로 한국어, 중국어, 일본어 등의 동아시아 문자가 모여 있는 문자 범위 중 한글이 아닌 문자와 일본어 문자 혼입 여부를 정규식으로 검사하였다. 최종 모델의 외국어 문자 혼입은 0건이었다.

8. Experimental Results

8.1. 20,000문항 본 학습

20,000문항 본 학습은 concept 9000 최종 adapter에서 이어서 진행하였다. Learning Rate는 3×10^{-6}으로 낮게 설정하고 1 epoch만 학습하였으며, 결과는 [Table 5]와 같이 나왔다.

항목	설정
시작 Adapter	qwen2_5_1_5b_concept9000_variant_qlora_r64_from3000/final
최종 Adapter	qwen2_5_1_5b_concept20000_variant_qlora_r64_from9000/final
Train Examples	20,000
Validation Examples	600
Epochs	1
Optimizer Steps	10,000
Learning Rate	3×10^{-6}
Best/Final Validation Loss	0.0000671783
Final Validation Perplexity	1.00006718
Test Result	599/600
Failed Cases	1
Foreign Character Mixing	0

[Table 5] Concept 20000 학습 결과

Validation Loss와 Perplexity가 1에 매우 가깝게 나온 것은, 600개 개념이라는 좁은 도메인과 짧고 규칙적인 답변 패턴에 모델이 강하게 맞춰졌기 때문이다. 유일한 실패는 문장 분리 예외 문항이었다. 정답 방향은 맞았으나, 강의 예시인 Ph.D를 포함하지 않아 키워드 기준에서 미달하였다. 이는 모델이 개념 자체를 모르는 것이 아니라, 특정 예시를 회상하지 못한 유형이다.

8.2. 균형 보정 최종 학습

마지막 오류를 해결하기 위해 balanced repair 학습을 수행하였다. 단일 실패 문항만 반복 학습하는 방식이 아니라, 세 개의 민감 주제와 전체 개념 anchor를 함께 학습시켰으며, 이에 관한 결과는 [Table 6]과 같이 나왔

다.

항목	설정
시작 Adapter	qwen2_5_1_5b_concept20000_variant_qlora_r64_from9000/final
최종 Adapter	qwen2_5_1_5b_concept20000_variant_qlora_r64_from9000_balanced_repair/final
Target Rows	120
Anchor Rows	600
Total Train Examples	720
Validation Examples	600
Epochs	2
Optimizer Steps	720
Learning Rate	5×10^{-6}
Best Validation Loss	0.0000672633
Final Validation Loss	0.0000822481
Final Validation Perplexity	1.00008225

[Table 6] Balanced Repair 학습 결과

실제 서버 추론에서도 문제였던 질문인 마침표만 보고 문장을 나누면 왜 문제가 생기는지에 대해 모델은 마침표가 항상 문장의 끝을 뜻하지 않기 때문이라고 답하였다. 강의 예시인 Ph.D 같은 표현 안에도 마침표가 들어갈 수 있으므로, 문장의 끝인지 약어 일부인지 구분해야 한다고 설명하였다. 이는 최종 보정이 단순 점수 향상에 그치지 않고, 실제 강의 예시 회상까지 회복했음을 보여준다. [Table 7]은 최종 모델이 생성형 AI 강의 Q&A 도메인에서 얼마나 잘 동작하는지를 정리한 표이다.

평가 항목	결과	비고
Concept 20000 In-Concept Test	600/600	미학습 질문 표현 600개
실패 문항	0	자동 평가 기준
외국어 문자 혼입	0	중국어, 일본어 문자 조각 없음
민감 문항 Probe	3/3	문장 분리 예외, 잠재 공간 벡터 연산, Parsing 실패

[Table 7] 최종 도메인 특화 성능

9. Analysis

데이터 확대 효과 부분에서는 600개 원본 Q&A만 학습했을 때는 Train Recall은 달성할 수 있었으나, 학생이 질문 표현을 조금만 바꾸면 답변이 불안정해졌다. 작은 Adapter가 원문 질문과 답변의 표면적 연결만 강하게 암기했을 가능성이 큰 것으로 판단했다. 같은 개념을 다양한 질문 표현과 연결하는 학습은 아직 충분하지 않았다.

이를 개선하기 위하여 질문 표현을 3,000개, 9,000개, 20,000개로 확대하였으며, 이로 인하여 성능이 향상된 이유를 다음과 같이 분석하였다. 같은 답변 개념을 여러 질문 패턴과 연결하여 질문 표현 변화에 둔감해졌으며, 유사 개념 간 혼동을 줄이기 위해 각 주제의 핵심 키워드가 반복 노출되기에 향상되었다고 판단하였다. 또한, LoRA rank를 64로 설정하여 Adapter가 충분한 도메인 정보를 저장할 수 있었으며, 낮은 Learning Rate로 이어 학습하여 기존에 학습한 내용을 크게 손상시키지 않았다. 한편으로는 데이터 수를 늘린다고 항상 성능이 개선되는 것은 아니라는 것을 인지하고 있었다. 데이터가 중복되거나 오답을 포함하면 모델은 잘못된 패턴도

함께 학습하기에, 본 프로젝트에서는 질문 문자열 중복 검사, split overlap 검사, 실패 문항 분석을 반복하여 데이터 품질을 유지하였다.

균형 보정 부분에서는 실패 문항 하나만 강하게 반복 학습하는 방식은 직관적으로 타당해 보이지만, 작은 Adapter에서는 인접 개념의 표현 공간이 흔들릴 수 있다. 실제로 단일 실패 보정에서는 문장 분리 예외는 해결되었으나, GAN의 잠재 공간 벡터 연산과 fine-tuning 데이터 parsing 실패 문항에서는 새로운 오답이 발생하였다. 이는 catastrophic forgetting[10]의 소규모 형태로 볼 수 있다.

최종 Balanced Repair는 Target Row와 Anchor Row를 함께 사용하였다. Target Row는 실패 주제를 집중적으로 바로잡고, Anchor Row는 전체 600개 개념을 다시 제시하여 기존 지식을 유지하도록 하였다. 이 방식이 최종 600/600을 달성한 핵심적인 실험적 개선이었다.

10. Limitations and Future Work

최종 600/600 결과는 같은 600개 개념을 다른 표현으로 질문한 in-concept test에 대한 것이다. 이는 강의 자료 안의 핵심 개념을 견고하게 설명하는 성능을 의미하며, 강의 자료 밖의 완전히 새로운 개념에 대한 일반화 성능까지 포함하지는 않는다. 별도로, 학습 600개 개념에 포함되지 않은 held-out 30문항을 같은 자동 평가 기준으로 측정하였다. In-concept test 600/600과 달리, Held-out 문항에서는 통과 문항 수가 현저히 적었고, 일부는 인접 개념으로 빗나가거나 답변을 거부하는 양상이 관찰되었다. 따라서, 새로운 개념까지 확장하려면 더 많은 원천 Q&A와 별도 평가 세트가 필요하다.

자동 평가 역시 완전하지 않다. 문자열 유사도와 키워드 겹침은 대량 평가에 적합하지만, 모든 의미적 정답을 완벽히 판정하지는 못한다. 본 프로젝트는 데모 성능 확보를 위해 의도적으로 과적합을 허용하였다. 따라서, 본 모델은 강의 자료 Q&A 도메인에 특화된 Adapter로 이해하는 것이 타당하다.

데이터는 질문 표현 수는 크게 늘렸으나, 개념 수는 600개에 고정되어 있다. 더 넓은 강의 범위를 다루려면 새로운 PDF나 PPT, 과제 문제, 시험 대비 질문, 학생 실제 질문 로그 등을 추가해야 할 것이다.

이후에 개념 수를 600개에서 1,000개 이상으로 확대하여 강의 자료 커버리지를 높일 여지가 있다. 또한, 정의형, 비교형, 예시 설명형, 계산 및 공식 해석형 질문을 유형별로 나누어 구성하면 답변 품질을 더 세밀하게 제어할 수 있을 것으로 생각한다. 자동 평가를 통과한 답변 중 일부를 사람이 직접 채점하여 정확성, 이해용이성, 강의 자료 충실도를 검증하는 절차도 필요하다고 판단한다.

QLoRA adapter가 도메인 스타일과 핵심 개념을 담당하고, 검색 기반 문맥 제공이 PDF 원문 근거를 보완하면 hallucination을 더 줄일 수 있으며, LoRA adapter를 base model에 병합한 뒤 4-bit 양자화 형식으로 변환하고, 모바일 추론 엔진과 간단한 채팅 UI를 결합하면 실제 핸드폰 속 전공 조교로 확장할 수 있을 것으로 기대한다.

11. Conclusion

본 프로젝트는 전공 공부 중 핸드폰에서 무료로 바로 질문할 수 있는 로컬 AI 조교라는 문제의식에서 출발하였다. 이를 위하여 Transformer부터 QLoRA fine-tuning까지 수업에서 다룬 8개 강의 PDF를 기반으로 Q&A 자료를 수집하고 정제한 뒤, Qwen chat template에 맞게 가공하였고, Qwen2.5-1.5B-Instruct를 QLoRA로 fine-tuning 하여 생성형 AI 과목 특화 챗봇을 구축하였다.

초기 600개 원본 Q&A 암기만으로는 질문 표현 변화에 취약했으나, 같은 600개 개념에 대한 paraphrase 학습 데이터를 3,000개, 9,000개, 20,000개로 확대하면서 in-concept test 성능이 585/600, 599/600까지 향상되었다. 이후 단일 실패 문항 보정이 다른 문항의 회귀를 유발할 수 있음을 확인하고, 취약 주제와 전체 개념 anchor를

함께 학습하는 balanced repair를 적용하여 최종 600/600을 달성하였다. 따라서, 본 챗봇은 직접 수집한 도메인 데이터로 사전학습 LLM을 fine-tuning 하여 특정 분야에 특화된 Q&A 챗봇을 구현하였다. 동시에 이 프로젝트는 Self-Attention, 프롬프트 설계, GAN, Diffusion model, parameter-efficient fine-tuning 등 수업 핵심 이론을 질문-답변 형태로 정리하고, 학생이 자신의 전공과목을 기기 안에 담아두고 인터넷이나 유료 서비스에 의존하지 않고 질문하는 학습 환경의 가능성을 보였다고 판단하였다.

본 프로젝트를 요약하면 다음과 같다.

A. 강의 자료 8개에서 600개 핵심 개념 Q&A를 구축하였다.

B. chat template에 맞춘 SFT 데이터로 변환하였다.

C. QLoRA를 사용해 제한된 GPU 환경에서도 학습을 수행하였다.

D. Train Recall이 아닌 미학습 질문 표현 Test로 도메인 성능을 확인하였고, Balanced Repair 전략으로 회귀를 방지하였다.

E. 이 Adapter를 모바일 양자화 모델로 확장하면 핸드폰 속 로컬 전공 조교라는 실사용 시나리오로 이어질 가능성을 제시하였다.

12. References

[1] A. Vaswani et al., "Attention Is All You Need," in Proc. Adv. Neural Inf. Process. Syst., 2017, pp. 5998–6008.

[2] I. Goodfellow et al., "Generative Adversarial Networks," in Proc. Adv. Neural Inf. Process. Syst., 2014, pp. 2672–2680.

[3] J. Ho, A. Jain, and P. Abbeel, "Denoising Diffusion Probabilistic Models," in Proc. Adv. Neural Inf. Process. Syst., 2020, pp. 6840–6851. [Online]. Available: https://arxiv.org/abs/2006.11239

[4] T. Dettmers et al., "QLoRA: Efficient Finetuning of Quantized LLMs," in Proc. Adv. Neural Inf. Process. Syst., 2023. [Online]. Available: https://arxiv.org/abs/2305.14314

[5] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models," in Proc. Int. Conf. Learn. Represent., 2022. [Online]. Available: https://openreview.net/forum?id=nZeVKeeFYf9

[6] Qwen Team, "Qwen2.5-1.5B-Instruct," Hugging Face, 2024. [Online]. Available: https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct

[7] J. Wei et al., "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," in Proc. Adv. Neural Inf. Process. Syst., 2022. [Online]. Available: https://arxiv.org/abs/2201.11903

[8] T. Wolf et al., "Transformers: State-of-the-Art Natural Language Processing," in Proc. EMNLP Syst. Demonstrations, 2020, pp. 38–45. [Online]. Available: https://aclanthology.org/2020.emnlp-demos.6/

[9] Python Software Foundation, "Python Programming Language," [Online]. Available: https://www.python.org/

[10] M. McCloskey and N. J. Cohen, "Catastrophic Interference in Connectionist Networks: The Sequential Learning Problem," in Psychology of Learning and Motivation, vol. 24, G. H. Bower, Ed. Academic Press, 1989, pp. 109–165.

Appendix A: Reproducibility

A.1. 20,000문항 학습 명령

```
ROOT=lora_outputs
PREV9=qwen2_5_1_5b_concept9000_variant_qlora_r64_from3000
BASE20=qwen2_5_1_5b_concept20000_variant_qlora_r64_from9000
PREV="$ROOT/$PREV9/final"
OUT="$ROOT/$BASE20"
python train_qlora_qwen.py \
  --train-file qa_dataset/concept20000_train_sft_messages.jsonl \
  --val-file qa_dataset/concept20000_validation_sft_messages.jsonl \
  --output-dir "$OUT" \
  --resume-adapter "$PREV" \
  --epochs 1 \
  --batch-size 2 \
  --grad-accum 1 \
  --lr 3e-6 \
  --weight-decay 0.0 \
  --eval-every 2000 \
  --max-length 512 \
  --lora-r 64 \
  --lora-alpha 128 \
  --lora-dropout 0.0 \
  --max-new-tokens 160
```

A.2. Balanced Repair 학습 명령

```
ROOT=lora_outputs
BASE20=qwen2_5_1_5b_concept20000_variant_qlora_r64_from9000
REPAIR="${BASE20}_balanced_repair"
PREV="$ROOT/$BASE20/final"
OUT="$ROOT/$REPAIR"
python train_qlora_qwen.py \
  --train-file qa_dataset/concept20000_balanced_repair_sft_messages.jsonl \
  --val-file qa_dataset/concept20000_validation_sft_messages.jsonl \
  --output-dir "$OUT" \
  --resume-adapter "$PREV" \
  --epochs 2 \
  --batch-size 2 \
  --grad-accum 1 \
  --lr 5e-6 \
  --weight-decay 0.0 \
  --eval-every 360 \
  --max-length 512 \
```

```
  --lora-r 64 \
  --lora-alpha 128 \
  --lora-dropout 0.0 \
  --max-new-tokens 160
```

A.3. 최종 평가 명령

```
ROOT=lora_outputs
BASE20=qwen2_5_1_5b_concept20000_variant_qlora_r64_from9000
REPAIR="${BASE20}_balanced_repair"
ADAPTER="$ROOT/$REPAIR/final"
OUT_JSON="$ROOT/$REPAIR/test600_eval.json"
python evaluate_assignment_demo.py \
  --adapter-dir "$ADAPTER" \
  --validation-file qa_dataset/concept20000_test_sft_messages.jsonl \
  --output-file "$OUT_JSON" \
  --dtype float16 \
  --max-new-tokens 180 \
  --similarity-threshold 0.58 \
  --keyword-threshold 0.45
```

Appendix B: Data Artifacts

B.1. Submission Code and Execution

파일	역할
extract_materials_text.py	강의 자료 텍스트 추출
merge_validate_qa.py, audit_qa_dataset.py	Q&A 병합, 중복 및 형식 검사
build_memorization600_sft.py	600개 원본 Q&A SFT 데이터 생성
build_concept3000_splits.py	3,000문항 개념 변형 split 생성
build_concept9000_splits.py	9,000문항 개념 변형 split 생성
build_concept20000_splits.py	20,000문항 개념 변형 split 생성
build_balanced_repair_sft.py	최종 균형 보정 데이터 생성
train_qlora_qwen.py	QLoRA 학습 스크립트
evaluate_assignment_demo.py	생성 기반 평가 스크립트
run_assignment_demo_chat.py	최종 챗봇 실행 스크립트

[Table 8] 주요 코드 파일

최종 모델 실행 예시

```
cd ~/sisaed_runs
source .venv/bin/activate
export CUDA_VISIBLE_DEVICES=0
python run_assignment_demo_chat.py \
  --dtype float16 \
  --question "QLoRA에서 Q는 quantum이 아니라 뭘 뜻하나요?“
```

최종 Adapter 경로

```
~/sisaed_runs/lora_outputs/qwen2_5_1_5b_concept20000_variant_qlora_r64_from9000_balanced_repair/
final
```

B.2. 주요 산출물 경로

파일 또는 경로	역할
qa_dataset/concept20000_manifest.json	최종 split 통계와 중복 검사 결과
qa_dataset/concept20000_train_sft_messages.jsonl	20,000개 train 메시지 데이터
qa_dataset/concept20000_validation_sft_messages.jsonl	600개 validation 메시지 데이터
qa_dataset/concept20000_test_sft_messages.jsonl	600개 test 메시지 데이터
qa_dataset/concept20000_balanced_repair_sft_messages.jsonl	720개 balanced repair 데이터
lora_outputs/.../training_summary.json	20,000 문항 본 학습 요약
lora_outputs/..._balanced_repair/training_summary.json	최종 보정 학습 요약

파일 또는 경로	역할
lora_outputs/.../concept20000_balanced_repair_test600_eval.json	최종 600 문항 test 결과

[Table 9] 주요 산출물 경로